



پردازش زبان طبیعی پیشرفته

نیم سال اول سال تحصیلی ۱۴۰۴-۱۴۰۵

شماره ترم: 4051

دانشگاه علم و صنعت ایران

دانشکده مهندسی کامپیوتر

آزمایشگاه پردازش زبان طبیعی (NLP Lab)

پروژه جامع درس پردازش زبان طبیعی پیشرفته

طراحی و پیاده سازی سامانه پاسخ گویی به پرسش های حقوقی با RAG و Graph RAG

تاریخ انتشار پروژه: دوشنبه ۷ مهر ۱۴۰۴

مهلت تحویل فاز نهایی: چهارشنبه ۱ بهمن ۱۴۰۴

شیوه انجام: انفرادی (سامانه LMS)

مدرس درس: دکتر بهروز مینایی بیدگلی

مدیر دوره: دکتر نجمه ترابیان

سرپرست دستیاران آموزشی: پوریا صانعی

دستیاران آموزشی مسئول پروژه (Project TAs)

محمد امین حائری

@rstlss0

علیرضا محمدی

@Alireza2001923

محمد خاکی

@khaki_mim

مریم مرتضوی نیک

@thisisnikk

خلاصه اجرایی پروژه

این پروژه در قالب طراحی، پیاده سازی و ارزیابی تجربی یک سامانه پاسخ گویی به پرسش های حقوقی فارسی مبتنی بر روش های RAG و Graph RAG تعریف شده است. دانشجویان در طول ۹ فاز پیوسته، با مؤلفه های اساسی سامانه های مدرن مبتنی بر مدل های زبانی بزرگ، شامل پیش پردازش استاندارد، قطعه بندی آگاه از ساختار، تعبیه سازی برداری، بازیابی متراکم و تنک، بازیابی ترکیبی (Hybrid)، بازرتبه بندی (Reranking)، مهندسی اعلان، هماهنگ سازی جریان کار با LangGraph، بازیابی مبتنی بر گراف دانش و ارزیابی کمی و کیفی جامع آشنا خواهند شد.

۱ قوانین و راهنمای تحویل پروژه

الزامات و قالب تحویل خروجی‌ها

دانشجویان محترم ملزم به رعایت دقیق ساختار و الزامات تحویل زیر هستند:

- **انفرادی بودن پروژه:** این پروژه به صورت کاملاً **انفرادی** تعریف شده و هر دانشجو باید تمامی مراحل، پیاده‌سازی‌ها و گزارش‌ها را به طور مستقل انجام دهد.
- **گزارش فنی (Technical Report):** تدوین فایل PDF مرتب و خوانا در ۲ تا ۳ صفحه برای هر فاز.
- **کدنویسی و نوت‌بوک‌ها:** ارائه تمامی فایل‌های پیاده‌سازی در قالب نوت‌بوک‌های استاندارد ipynb. با خروجی‌های ذخیره‌شده.
- **نام‌گذاری و بارگذاری:** فایل فشرده HW<Phase>_<StdID>.zip (مثال: HW1_401234567.zip) به همراه لینک مخزن GitHub در گزارش.

مهلت‌ها و سیاست تأخیر (Late Policy)

- **زمان‌بندی فازها:** تحویل فازها در قالب ۵ ایستگاه زمان‌بندی شده تعریف شده است (مهلت تحویل نهایی فاز ۹: ۱ بهمن ۱۴۰۴). جلسات ارزیابی و دفاع شفاهی پس از تحویل هر ایستگاه برگزار می‌گردد. تقویم کامل مهلت‌ها در بخش بعدی درج شده است.
- **تأخیر مجاز ترم:** هر دانشجو در طول ترم در مجموع دارای ۴۸ ساعت تأخیر مجاز است.
- **جریمه تأخیر مازاد:** پس از پایان سهمیه، به ازای هر ساعت تأخیر، نیم نمره از نمره کل (۱۰۰ نمره) کسر خواهد شد.
- **پاداش ارسال زودهنگام:** ارسال پیش از موعد با نمره بیش از ۸۰ درصد، حداکثر ۲۴ ساعت به سهمیه مجاز می‌افزاید.
- **بسته شدن قطعی سامانه:** سامانه ارسال تکالیف دقیقاً ۴ روز پس از مهلت رسمی بسته می‌شود.

الزامات شیوه ارزیابی و بارم‌بندی (Grading Scheme)

- **پیاده‌سازی فازها و گزارش فنی (۴۰ درصد):** صحت الگوریتم‌ها، تمیزی کد، قابلیت بازتولید (Reproducibility) و مستندسازی دقیق تحویلی‌ها.
- **ارائه حضوری و دفاع شفاهی (۶۰ درصد):** تسلط کامل علمی دانشجو بر جزئیات پیاده‌سازی، پاسخ‌گویی به سؤالات مفهومی و دفاع از تصمیمات طراحی در برابر دستیاران آموزشی.
- **جلسات ارزیابی و دفاع:** ارزیابی و دفاع شفاهی انفرادی پس از تحویل هر ایستگاه، و جلسات دفاع نهایی کل پروژه در روزهای ۴ تا ۷ بهمن ۱۴۰۴ با دستیاران آموزشی برگزار خواهد شد.

سیاست صداقت دانشگاهی و منع سرقت علمی

تمامی فایل‌های ارسالی باید حاصل تلاش مستقل دانشجو باشد. بررسی شباهت‌سنجی کد و متن به صورت خودکار انجام خواهد شد. در صورت مشاهده هرگونه کپی‌برداری یا شباهت غیرمعارف، برای تمام طرفین درگیر حداقل ۵۰ درصد جریمه نمره در نظر گرفته شده و موارد به کمیته انضباطی ارجاع داده می‌شود.

نحوه ارتباط و پاسخ به سؤالات

دانشجویان محترم جهت رفع اشکال، سؤالات فنی و ابهامات هر فاز را در پیام‌رسان تلگرام مستقیماً از دستیاران آموزشی (TA) مسئول همان فاز جویا شوند.

۲ تقویم زمان‌بندی، مهلت‌های تحویل و جلسات ارزیابی

پروژه در قالب ۵ ایستگاه زمان‌بندی شده سازمان‌دهی شده است. در هر یک از چهار ایستگاه نخست، فازها به صورت زوجی (دو فاز هم‌گام) تحویل داده شده و ارزیابی شفاهی آن‌ها بلافاصله در هفته بعد برگزار می‌گردد. ایستگاه پنجم به فاز پایانی و ارزیابی نهایی و دمو جامع کل سامانه اختصاص دارد:

جدول جامع زمان‌بندی مهلت‌های تحویل فازها و جلسات دفاع شفاهی

ایستگاه / مرحله	فازها و محورهای پیاده‌سازی	مهلت تحویل فاز (Deadline)	بازه دفاع شفاهی / ارائه
انتشار صورت پروژه	انتشار فایل پروژه و داده‌های خام	دوشنبه ۷ مهر ۱۴۰۴	—
ایستگاه اول (Milestone 1)	فاز ۱ و ۲: پیش‌پردازش، استانداردسازی، قطعه‌بندی و تعبیه‌سازی برداری	چهارشنبه ۳۰ مهر ۱۴۰۴ (ساعت 23:59)	شنبه ۳ تا چهارشنبه ۷ آبان (دفاع فازهای ۱ و ۲ با TA)
ایستگاه دوم (Milestone 2)	فاز ۳ و ۴: پایگاه برداری Qdrant و بازسازی سامانه با LangChain	چهارشنبه ۲۱ آبان ۱۴۰۴ (ساعت 23:59)	شنبه ۲۴ تا چهارشنبه ۲۸ آبان (دفاع فازهای ۳ و ۴ با TA)
ایستگاه سوم (Milestone 3)	فاز ۵ و ۶: بازیابی ترکیبی، Reranking، مهندسی پرامپت و تولید پاسخ	چهارشنبه ۱۲ آذر ۱۴۰۴ (ساعت 23:59)	شنبه ۱۵ تا چهارشنبه ۱۹ آذر (دفاع فازهای ۵ و ۶ با TA)
ایستگاه چهارم (Milestone 4)	فاز ۷ و ۸: ارکستراسیون با LangGraph و پیاده‌سازی Graph RAG	چهارشنبه ۳ دی ۱۴۰۴ (ساعت 23:59)	شنبه ۶ تا چهارشنبه ۱۰ دی (دفاع فازهای ۷ و ۸ با TA)
ایستگاه پایانی (Final Milestone)	فاز ۹: ارزیابی جامع، تحلیل خطا، مطالعات ابلیشن و کد نهایی یکپارچه	چهارشنبه ۱ بهمن ۱۴۰۴ (ساعت 23:59)	شنبه ۴ تا سه‌شنبه ۷ بهمن (ارزیابی نهایی و دمو)

ضوابط تحویل ایستگاهی، ارزیابی حضوری، مهلت پایانی و قفل نمرات

- **تحویل ایستگاهی فازها:** تحویل پروژه در قالب ۵ ایستگاه زمان‌بندی شده (۴ ایستگاه زوج فاز و ۱ ایستگاه پایانی) انجام می‌شود. هر تحویل شامل کدهای پیاده‌سازی، نوت‌بوک‌ها و گزارش فنی فازهای مربوطه است.
- **دفاع شفاهی پس از هر ایستگاه (سهم ۶۰ درصدی):** جلسات دفاع پس از تحویل هر ایستگاه در قالب جلسات انفرادی ۱۰ تا ۱۵ دقیقه‌ای با دستیار آموزشی (TA) مسئول فازها برگزار شده و تسلط دانشجو بر هر دو فاز ارزیابی خواهد شد.
- **انجام بلافاصله دفاع:** جلسات ارزیابی شفاهی بلافاصله از شنبه پس از تحویل فازها آغاز می‌شود تا بازخورد فنی در همان مقطع به دانشجو منتقل گردد.
- **مهلت تحویل نهایی فاز ۹:** مهلت ارسال نتایج نهایی، تحلیل خطا و گزارش فاز ۹ تا چهارشنبه ۱ بهمن ۱۴۰۴ (ساعت 23:59) است؛ ارزیابی نهایی و دمو جامع پروژه در روزهای شنبه ۴ تا سه‌شنبه ۷ بهمن ۱۴۰۴ برگزار می‌گردد.
- **قفل قطعی نمرات درس:** نمرات کل پروژه و درس در روز سه‌شنبه ۱۴ بهمن ۱۴۰۴ به‌طور قطعی در سامانه گلستان ثبت و قفل خواهد شد.

فهرست مطالب


۱	قوانین و راهنمای تحویل پروژه	۲
۲	تقویم زمان‌بندی، مهلت‌های تحویل و جلسات ارزیابی	۳
۳	مقدمه و تعریف مسئله	۵
۴	اهداف و چشم‌انداز پروژه	۵
۵	داده‌ها، پایگاه دانش و محدودیت‌ها	۶
۱.۵	مجموعه داده‌های پرسش و پاسخ و پایگاه قوانین	۶
۲.۵	معیارها و برچسب‌های فیلتر داده‌ها	۷
۶	مراحل انجام پروژه	۸
۱.۶	فاز ۱: پیش‌پردازش و استانداردسازی داده‌ها	۸
۲.۶	فاز ۲: قطعه‌بندی و تعبیه‌سازی برداری	۱۰
۳.۶	فاز ۳: بازیابی متراکم و سامانه پایه RAG	۱۱
۴.۶	فاز ۴: بازسازی سامانه با LangChain	۱۳
۵.۶	فاز ۵: بهینه‌سازی و مقایسه روش‌های بازیابی	۱۴
۶.۶	فاز ۶: مهندسی اعلان و تولید پاسخ (Prompt Engineering)	۱۵
۷.۶	فاز ۷: هماهنگ‌سازی جریان سامانه با LangGraph	۱۶
۸.۶	فاز ۸: طراحی و پیاده‌سازی RAG Graph	۱۷
۹.۶	فاز ۹: ارزیابی نهایی، تحلیل خطا و یکپارچه‌سازی سامانه	۱۸

۳ مقدمه و تعریف مسئله

در این پروژه، هدف طراحی، پیاده‌سازی و ارزیابی تجربی یک سامانه جامع پاسخ‌گویی به پرسش‌های حقوقی فارسی مبتنی بر سامانه RAG (Retrieval-Augmented Generation) است. سامانه باید بتواند با جست‌وجو در پیکره اسناد قوانین حقوقی کشور و با تکیه بر مجموعه داده پرسش و پاسخ، مرتبط‌ترین مستندات قانونی و مواد حقوقی متناظر با هر پرسش را با دقت بالا بازایی کرده و سپس بر اساس شواهد بازایی‌شده و زمینه‌سازی دقیق، پاسخی دقیق، مستند و پایبند به قانون تولید نماید.

این پروژه در قالب یک سامانه چندحوزه‌ای RAG با تمرکز ویژه بر دو زیرحوزه پرکاربرد «حقوق خانواده» و «حقوق ارث» طراحی شده است. فرایند کلی پروژه در قالب ۹ فاز متوالی و هدفمند سازمان‌دهی شده که از آماده‌سازی و استانداردسازی پیکره آغاز شده، از مسیر قطعه‌بندی هوشمند، تعبیه‌سازی، بازایی متراکم و تنک، بازایی ترکیبی (Hybrid Search)، بازرتبه‌بندی (Reranking)، بازسازی ساختار با LangChain، هماهنگ‌سازی جریان تصمیم‌گیری با LangGraph و پیاده‌سازی گراف دانش در Graph RAG عبور کرده و به ارزیابی جامع کمی و کیفی منتهی می‌شود.

در تمامی مراحل انجام پروژه، تأکید بنیادین بر قابلیت بازتولید آزمایش‌ها (Reproducibility) و تحلیل تجربی اثر هر مؤلفه است. از این رو، دانشجویان موظف‌اند علاوه بر پیاده‌سازی گام به گام سامانه، تأثیر تغییر هر یک از پارامترها و مؤلفه‌ها را از طریق آزمایش‌های کنترل‌شده و مقایسه‌های تجربی در قالب گزارش فنی مستند سازند.



شکل ۱. شمای کلی جریان کار و فازهای نه‌گانه پروژه جامع سامانه RAG حقوقی

۴ اهداف و چشم‌انداز پروژه

طراحی و فرضیات اجرایی این پروژه بر مبنای تکامل تدریجی و مهندسی‌شده یک سامانه RAG حقوقی و ارزیابی کنترل‌شده تک‌تک اجزای آن پایه‌ریزی شده است. در این مسیر، ابتدا بستر داده و پایگاه دانش استانداردسازی می‌شود، سپس سامانه پایه طراحی و اعتبارسنجی شده و در ادامه مؤلفه‌های پیشرفته بازایی، بازسازی معماری با فریم‌ورک‌های استاندارد، تصمیم‌گیری گراف و ارزیابی عمیق به سامانه تزریق می‌گردند. اهداف نه‌گانه پروژه به شرح زیر دنبال می‌شوند:

۱. پیش‌پردازش و استانداردسازی داده‌ها (Preprocessing & Standardization): استخراج هوشمند متن اسناد حقوقی، پاک‌سازی، یکسان‌سازی نویسه‌ها، حذف تکرارها، استخراج فراداده‌ها (Metadata) و ادغام اسناد در یک شمای استاندارد یکپارچه (Unified Document Schema).

۲. قطعه‌بندی و تعبیه‌سازی برداری (Chunking & Embedding): طراحی و مقایسه تجربی دو رویکرد قطعه‌بندی با پنجره ثابت (Fixed-Size) و آگاه از ساختار حقوقی (Structure-Aware)، تولید بردارهای معنایی با مدل Qwen/Qwen3-Embedding-0.6B و تحلیل توزیع آماری قطعات.

۳. بازایی متراکم و سامانه پایه (Dense Retrieval & Baseline RAG): نمایه‌سازی بردارها در پایگاه داده برداری Qdrant، پیاده‌سازی سازوکار بازایی متراکم مبتنی بر شباهت کسینوسی و ساخت یک خط لوله پایه انتهابه‌انتها.

۴. بازسازی سامانه با LangChain: بازپیاده‌سازی معماری پایه با ابزارهای اکوسیستم LangChain، تحلیل شفاف جریان داده و مقایسه دقیق اثرات این تجرید بر کارایی و نتایج سامانه.

۵. بهینه‌سازی و ارتقای بازیابی (Retrieval Optimization): پیاده‌سازی جست‌وجوی تنک BM25، ترکیب نتایج با بازیابی ترکیبی (Hybrid Search) از طریق الگوریتم RRF و پالایش نهایی با مدل‌های بازرتبه‌بند (Cross-Encoder Reranking).
۶. مهندسی اعلان و تولید پاسخ (Prompt Engineering & Generation): طراحی و ارزیابی راهبردهای اعلان‌نویسی، کنترل دقیق مدل زبانی در پابندی به مستندات قانونی (Groundedness) و جلوگیری از توهم (Hallucination).
۷. هماهنگ‌سازی جریان کار با LangGraph: مدل‌سازی معماری سامانه به صورت گراف محاسباتی شامل وضعیت (State)، گره‌ها (Nodes) و یال‌های شرطی (Conditional Edges) برای افزایش تاب‌آوری فرآیند.
۸. طراحی و پیاده‌سازی Graph RAG: استخراج موجودیت‌ها و روابط حقوقی، تشکیل گراف دانش (Knowledge Graph) و بازیابی بر مبنای زیرگراف برای پاسخ‌گویی به پرسش‌های چندمرحله‌ای (Multi-hop Reasoning).
۹. ارزیابی جامع، تحلیل خطا و یکپارچه‌سازی نهایی (Evaluation & Integration): ارزیابی تفکیک‌شده در دو سطح بازیابی و تولید پاسخ، اجرای مطالعات ابلیشن (Ablation Studies)، تحلیل کیفی خطاها، سنجش بار محاسباتی و یکپارچه‌سازی نسخه نهایی سامانه.

۵ داده‌ها، پایگاه دانش و محدودیت‌ها

داده‌های مورد استفاده در این پروژه از دو منبع بنیادین تشکیل یافته‌اند: مجموعه داده پرسش و پاسخ‌های حقوقی تخصصی و اسناد متنی قوانین رسمی کشور. تمامی پیاده‌سازی‌ها، آزمایش‌ها و ارزیابی‌های هر نه فاز باید صرفاً بر بستر همین مجموعه‌ها انجام پذیرند.

۱.۵ مجموعه داده‌های پرسش و پاسخ و پایگاه قوانین

مجموعه داده پرسش و پاسخ از پیکره استاندارد qa-persian-legal-iran/PerSets انتخاب شده که حاوی پرسش‌های واقعی کاربران و مشاوره‌های حقوقی مکتوب ارائه شده توسط کارشناسان و وکلای دادگستری است. در این پروژه، تمرکز بر دو حوزه مشخص «حقوق خانواده» و «حقوق ارث» قرار دارد. در مجموع تعداد ۱۰،۰۰۰ نمونه با استفاده از بذرمعین (seed=42) نمونه‌گیری شده و طبق جدول ۱ به بخش‌های آموزش، اعتبارسنجی و آزمون افراز شده‌اند:

جدول ۱. آمار تفکیکی تقسیم‌بندی مجموعه داده پرسش و پاسخ حقوقی (seed=42)

زیرمجموعه داده (Split)	حقوق خانواده	حقوق ارث	مجموع کل نمونه‌ها
مجموعه آموزش (Train Set)	۴۹۰۰ (۷۰٪)	۲۱۰۰ (۷۰٪)	۷۰۰۰ (۷۰٪)
مجموعه اعتبارسنجی (Validation Set)	۶۳۰ (۹٪)	۲۷۰ (۹٪)	۹۰۰ (۹٪)
مجموعه آزمون (Test Set)	۱۴۷۰ (۲۱٪)	۶۳۰ (۲۱٪)	۲۱۰۰ (۲۱٪)
مجموع کل نمونه‌ها	۷۰۰۰	۳۰۰۰	۱۰۰۰۰

اسناد پایگاه دانش (Knowledge Base)

منبع دانش رسمی سامانه که در تمامی فازهای بازیابی و ساخت گراف دانش استفاده خواهد شد، شامل متن کامل اسناد رسمی زیر است:

- قانون مدنی جمهوری اسلامی ایران
- قانون حمایت خانواده

این اسناد به‌عنوان منبع مستندات معتبر در نظر گرفته شده و میان آموزش و آزمون تقسیم نمی‌شوند؛ بلکه مرجع واحد تولید شواهد و پاسخ‌ها هستند.

۲.۵ معیارها و برچسب‌های فیلتر داده‌ها

انتخاب نمونه‌ها از مجموعه داده باید بر اساس برچسب‌های موضوعی صریح زیر انجام گیرد:

- برچسب‌های حقوق خانواده: مهریه، طلاق، نفقه، تمکین، حضانت، حضانت فرزند، جهیزیه، ازدواج، طلاق از طرف زن.
- برچسب‌های حقوق ارث: ارث، قوانین ارث، انحصار وراثت، تقسیم ارث.

قاعده غربال‌گری تداخل برچسب‌ها

نمونه‌هایی که به‌صورت هم‌زمان دارای برچسب‌های هر دو حوزه (حقوق خانواده و حقوق ارث) باشند، جهت جلوگیری از سوگیری و ابهام در ارزیابی تفکیک‌شده، از نمونه‌گیری اصلی حذف می‌شوند. انتخاب نهایی شامل ۷۰۰۰ نمونه خانواده و ۳۰۰۰ نمونه ارث است که کاملاً با `seed=42` تعیین گردیده است.

۶ مراحل انجام پروژه

پروژه در قالب ۹ فاز متوالی و به هم پیوسته انجام می‌شود. خروجی هر فاز مستقیماً ورودی فازهای بعدی است. در هر مرحله، دانشجو ملزم به ثبت شفاف تصمیمات مهندسی و تحلیل نتایج تجربی در گزارش خود خواهد بود.

۱.۶ فاز ۱: پیش‌پردازش و استانداردسازی داده‌ها

شناسنامه و مشخصات کلیدی این فاز

- **هدف فاز:** تبدیل اسناد خام قانونی و داده‌های پرسش و پاسخ به پیکره ساختاریافته، استاندارد و یکپارچه.
- **ورودی‌ها:** فایل‌های PDF قوانین رسمی و داده‌های خام مجموعه داده در پوشه `data/raw/`.
- **خروجی‌های مورد انتظار:** پیکره یکپارچه نهایی در قالب فایل `data/processed/corpus.json`.
- **نوت‌بوک‌های این فاز:** `pdf_extraction.ipynb`، `data_exploration.ipynb`، `build_corpus.ipynb`.
- **مهلت تحویل ایستگاه اول (فاز ۱ و ۲):** چهارشنبه ۳۰ مهر ۱۴۰۴ (ساعت 23:59) **بازه دفاع شفاهی:** ۳ تا ۷ آبان ۱۴۰۴

۱.۱.۶ ساختار استاندارد مخزن پروژه

پیش از آغاز پیاده‌سازی، دانشجو باید ساختار پوشه‌بندی زیر را در مخزن گیت‌هاب پروژه پیاده‌سازی نماید. این ساختار تفکیک مشخصی میان داده‌های خام و پردازش‌شده، مؤلفه‌های خط لوله RAG، پیکربندی‌ها و نتایج آزمایش‌ها ایجاد می‌کند:

```
ANLP-RAG/
  configs/           # Pipeline configuration files (YAML/JSON)
  data/
    raw/             # Original raw legal PDFs and QA datasets
    processed/       # Unified standardized corpus (JSON/JSONL)
  experiments/
    ablation/        # Scripts and logs for ablation studies
    results/         # Quantitative benchmark results and metrics
  rag/
    preprocessing/   # Data exploration, PDF parsing & cleaning
    chunking/        # Fixed-size and structure-aware chunkers
    embeddings/      # Vector representation pipelines
    retrieval/       # Dense, Sparse (BM25) and Hybrid search
    langchain/       # LangChain pipeline recreation
    reranking/       # Cross-encoder rerankers & fusion algorithms
    prompting/       # Prompt templates and context formatters
    langgraph/       # StateGraph orchestration & conditional routing
    graph_rag/       # Knowledge graph schema, indexing & retrieval
    generation/      # LLM generation and answer synthesizers
    evaluation/      # Retrieval and generation evaluation metrics
  main.py            # Unified end-to-end execution entry point
  README.md          # Setup, reproduction instructions & environment
  requirements.txt    # Python dependencies with pinned versions
```


۲.۱.۶ مراحل پیش پردازش و پاک سازی داده ها

فرایند پیش پردازش اسناد حقوقی و داده های پرسش و پاسخ باید مراحل استاندارد زیر را طی کند:

۱. **استخراج اسناد PDF:** استخراج دقیق متن از فایل های قوانین مدنی و حمایت خانواده با حفظ ساختار ماده ها، تبصره ها، شماره صفحات و عناوین فصول.
۲. **نرمال سازی متنی و نویسه ای:** یکسان سازی **Unicode**، تبدیل حروف عربی (مانند ي و ك) به نویسه های استاندارد فارسی (ی و ک)، حذف کشیدگی حروف (**Tatweel**)، تنظیم فواصل مجازی (**ZWNJ**) و حذف نویسه های کنترلی نامعتبر.
۳. **حذف داده های تکراری و نویزها:** شناسایی سربرها و پانویس های تکرارشونده در صفحات PDF، حذف تکرارها و علامت های نگارشی زائد.
۴. **یکپارچه سازی ساختار داده:** الحاق فراداده های تفکیک کننده (**Metadata**) نظیر شماره ماده، نام سند، شماره صفحه و برچسب های موضوعی.

۳.۱.۶ قالب استاندارد سند نهایی (Unified Document Schema)

خروجی نهایی این فاز باید به صورت یک فایل **JSON** ذخیره شود که در آن هر سند یا ماده قانونی یک آبجکت مستقل با ساختار استاندارد زیر باشد:

```
{
  "id": "unique_document_id",
  "title": "document_or_article_title",
  "text": "normalized_cleaned_text",
  "domain": "family | inheritance",
  "source": "civil_code | family_protection_law | persets_qa",
  "metadata": {
    "page": 12,
    "article": "1085",
    "qa_id": null,
    "tags": ["family_law", "marriage"]
  },
  "provenance": {
    "original_source": "civil_code.pdf",
    "extracted_at": "2026-09-12"
  }
}
```

فیلدهای **page** و **article** برای اسناد قانونی الزامی بوده و فیلد **qa_id** برای داده های پرسش و پاسخ تخصیص می یابد. شناسه **id** باید در کل پیکره یکتا و ارجاع پذیر باشد.

❓ پرسش های تحویلی و مستند سازی این فاز

۱. **لینک مخزن گیت هاب:** پیوند عمومی یا دسترسی مخزن **GitHub** پروژه را به همراه کامیت نهایی فاز ۱ درج نمایید.
۲. **مستند سازی نوت بوک ها:** برای هر یک از نوت بوک های سه گانه (**data_exploration**، **pdf_extraction** و ...)

build_corpus) در یک پاراگراف مختصر، هدف نوت‌بوک، چالش‌های اصلی متن فارسی و راهکارهای اعمال‌شده را تحلیل فرمایید.

۳. تحلیل آماری پیکره: جدول آمار توصیفی اسناد نهایی (شامل تعداد اسناد هر حوزه، میانگین و بیشینه طول نویسه‌ها و کلمات) را ارائه دهید.

۴. بررسی نمونه‌های تصفیه‌شده: دو نمونه از اسناد را پیش و پس از نرمال‌سازی در گزارش مقایسه کرده و تأثیر اصلاح نویسه‌ها را شرح دهید.

۲.۶ فاز ۲: قطعه‌بندی و تعبیه‌سازی برداری

📚 شناسنامه و مشخصات کلیدی این فاز

- **هدف فاز:** تجزیه اسناد حقوقی به قطعات بهینه برای بازیابی و استخراج بردارهای معنایی با مدل پایه.
- **ورودی‌ها:** فایل پیکره یکپارچه استخراج‌شده در فاز قبل (data/processed/corpus.json).
- **خروجی‌های مورد انتظار:** دو فایل قطعات fixed_chunks.jsonl و structure_chunks.jsonl و بردارهای امبدینگ ۱۰۲۴ بعدی.
- **نوت‌بوک‌های این فاز:** tokenizer ، fixed_chunker ، legal_chunker ، chunking_experiment ، embedding ، evaluate_chunks .
- **مهلت تحویل ایستگاه اول (فاز ۱ و ۲):** چهارشنبه ۳۰ مهر ۱۴۰۴ (ساعت 23:59) 📅 **بازه دفاع شفاهی:** شنبه ۳ تا چهارشنبه ۷ آبان ۱۴۰۴

پس از آماده‌سازی پیکره استاندارد، در این فاز اسناد به قطعات مناسب برای بازیابی تقسیم شده و برای هر قطعه بردار تعبیه‌ای تولید می‌شود. هدف، ایجاد دو نسخه قابل مقایسه از قطعات و بررسی اثر راهبرد قطعه‌بندی بر ساختار داده ورودی مراحل بازیابی است.

۱.۲.۶ راهبردهای قطعه‌بندی اسناد (Chunking Strategies)

دانشجو ملزم است دو روش قطعه‌بندی زیر را به‌طور مستقل پیاده‌سازی و مقایسه نماید:

۱. **قطعه‌بندی با اندازه ثابت (Fixed-Size Chunking):** پیاده‌سازی با استفاده از پنجره لغزان (Sliding Window) و هم‌پوشانی توکن‌ها.

۲. **قطعه‌بندی آگاه از ساختار حقوقی (Structure-Aware Chunking):** قطعه‌بندی با پایبندی به مرزهای طبیعی مواد قانونی، تبصره‌ها و بندها.

در روش اندازه ثابت، اندازه پنجره بر اساس تعداد توکن‌ها با توکنایزر رسمی مدل Qwen/Qwen3-Embedding-0.6B تعیین می‌شود. با فرض اندازه قطعه C و هم‌پوشانی O ، گام جابه‌جایی پنجره (Stride) برابر است با:

$$S = C - O \quad (1)$$

پیکربندی پایه این روش برابر $C = 256$ توکن و $O = 64$ توکن تعیین می‌شود و توکن‌های ویژه (Special Tokens) در محاسبه طول لحاظ نمی‌شوند.

در روش آگاه از ساختار، مرز هر ماده قانونی باید تا حد امکان حفظ شود. چنانچه طول یک ماده بیش از ۲۵۶ توکن باشد، آن ماده به چند زیرقطعه شکسته می‌شود؛ اما متن دو ماده مستقل هرگز نباید در یک قطعه ادغام گردد. در این روش هم‌پوشانی برابر صفر در نظر گرفته می‌شود.

برای هر قطعه، اطلاعات منشأ شامل `chunk_id`، `doc_id`، متن قطعه، حوزه، فراداده سند و تعداد توکن‌ها در قالب JSONL ذخیره می‌گردد.

۲.۲.۶ ارزیابی و تحلیل آماری قطعات (Chunking Evaluation)

دانشجو باید دو راهبرد قطعه‌بندی را از نظر سنج‌های آماری زیر مقایسه کند:

- تعداد کل قطعات تولیدشده و میانگین تعداد قطعه به ازای هر سند.
- توزیع طول قطعات بر حسب توکن: میانگین، میانه، انحراف معیار، کمینه، بیشینه و صدک‌های ۹۰، ۹۵ و ۹۹.
- درصد قطعاتی که بیش از سقف ۲۵۶ توکن یا کمتر از ۲۰ توکن هستند.

۳.۲.۶ تولید بردارهای معنایی (Vector Embeddings)

برای هر دو پیکره قطعه‌بندی‌شده، با استفاده از مدل Qwen/Qwen3-Embedding-0.6B بردار تعبیه متناظر با هر قطعه با بعد ۱۰۲۴ تولید می‌شود. شرایط و تنظیمات استخراج بردار (شامل `batch_size`، `device`، روش **Pooling** و نرمال‌سازی) باید برای هر دو روش کاملاً یکسان باشد تا مقایسه‌ای منصفانه حاصل گردد.

❓ پرسش‌های تحویلی و مستندسازی این فاز

۱. مخزن گیت‌هاب: لینک مخزن و کامیت متناظر با پایان فاز ۲ را درج کنید.
۲. جدول مقایسه آماری: جدول جامع توزیع طول و تعداد قطعات را برای دو روش **Fixed-Size** و **Structure-Aware** گزارش دهید.
۳. تحلیل چالش‌های مواد طولانی: در روش آگاه از ساختار، موادی که طول آن‌ها از حد آستانه بیشتر بود چگونه مدیریت شدند؟ اثر این تصمیم بر حفظ یکپارچگی معنایی ماده چه بوده است؟
۴. تحلیل آمادگی برای نمایه‌سازی: آیا بردارها از نظر بعد، مقادیر معتبر (Non-NaN) و نرمال‌سازی L_2 بررسی شده‌اند؟

۳.۶ فاز ۳: بازیابی متراکم و سامانه پایه RAG

📖 شناسنامه و مشخصات کلیدی این فاز

- **هدف فاز:** نمایه‌سازی بردارها در Qdrant، پیاده‌سازی بازیابی متراکم و اتصال مسیر پایه پرسش و پاسخ.
- **ورودی‌ها:** قطعات و بردارهای ۱۰۲۴ بعدی تولیدشده در فاز ۲.
- **خروجی‌های مورد انتظار:** دو کالکشن مستقل در Qdrant، خط لوله بازیابی و نتایج مقایسه عملکرد قطعه‌بندی.
- **فناوری‌های کلیدی:** پایگاه داده برداری Qdrant (حالت حافظه‌ای)، مدل Qwen3-Embedding-0.6B.
- **مهلت تحویل ایستگاه دوم (فاز ۳ و ۴):** چهارشنبه ۲۱ آبان ۱۴۰۴ (ساعت ۲۳:۵۹) 🕒 **بازه دفاع شفاهی:** ۲۴ تا ۲۸ آبان ۱۴۰۴

در این فاز، دانشجو باید بر اساس قطعات و بردارها، سازوکار بازیابی متراکم (**Dense Retrieval**) را با استفاده از پایگاه داده برداری Qdrant پیاده‌سازی کند. هدف اصلی، ایجاد یک مسیر بازیابی قابل‌بازآفرینی و مقایسه کنترل‌شده دو روش قطعه‌بندی فاز قبل است.

۱.۳.۶ بارگذاری و نمایه‌سازی در Qdrant

برای مقایسه دقیق، دو کالکشن مجزا در Qdrant ایجاد می‌شود:

- `legal_fixed_256_64`: قطعات روش اندازه ثابت با هم‌پوشانی.
- `legal_structure_aware`: قطعات منطبق بر مرز مواد قانونی بدون هم‌پوشانی.

هر دو کالکشن باید با بعد ۱۰۲۴ و با متریک شباهت کسینوسی (**Cosine Similarity**) پیکربندی شوند. اطلاعات متنی و فراداده‌ها (metadata) در بخش **Payload** رکوردها ذخیره شوند تا امکان ردیابی منبع قطعات بازیابی شده فراهم گردد.

۲.۳.۶ تولید بردار پرسش (Query Embedding)

برای هر پرسش کاربر، بردار پرسش با مدل `Qwen/Qwen3-Embedding-0.6B` تولید می‌شود. این فرایند شامل توکنایز کردن پرسش (حداکثر طول ۲۵۶ توکن)، استخراج لایه‌های پنهان، اعمال **Last-Token Pooling** و نرمال‌سازی L_2 بردار است.

🔑 شرط مقایسه کنترل شده

بردار هر پرسش آزمایشی باید دقیقاً یک‌بار تولید شده و همان بردار واحد برای جست‌وجو در هر دو کالکشن استفاده گردد تا تأثیر متغیرهای تصادفی به صفر برسد.

۳.۳.۶ پیاده‌سازی بازیابی متراکم و محاسبه شباهت

تابع بازیابی باید با دریافت پرسش، k قطعه دارای بالاترین امتیاز شباهت را بازگرداند (پیش‌فرض $k = 5$). امتیاز شباهت کسینوسی میان بردار پرسش q و بردار قطعه d طبق رابطه زیر محاسبه می‌شود:

$$\text{sim}(q, d) = \frac{q^T d}{\|q\|_2 \|d\|_2} \quad (2)$$

۴.۳.۶ اتصال به مسیر انتها به انتها (End-to-End Pipeline)

قطعات بازیابی شده برای تشکیل زمینه (**Context**) در اختیار مدل زبانی قرار می‌گیرند تا مسیر پایه زیر به شکل مستقیم پیاده‌سازی گردد:

Query → Query Embedding → Dense Retrieval → Context Construction → Prompt → LLM Generation

🚫 محدودیت فنی فاز ۳

در این فاز استفاده از پکیج‌های سطح بالای **LangChain** یا **LangGraph** مجاز نیست؛ دانشجو باید جریان داده و محاسبات را مستقیماً کدنویسی کند تا تسلط بر لایه‌های زیرین سامانه تثبیت گردد.

🔗 پرسش‌های تحویلی و مستندسازی این فاز

۱. لینک گیت‌هاب: لینک نوت‌بوک‌های اجرایی و کالکشن‌های فاز ۳.
۲. مقایسه کیفی ۵ پرسش نمونه: ۵ پرسش منتخب از حوزه‌های خانواده و ارث را در هر دو کالکشن اجرا کرده و

تفاوت قطعات بازیابی شده (از نظر رتبه، امتیاز شباهت و دقت تطابق با سوال) را در جدولی مقایسه کنید.

۳. تحلیل عملکرد روش‌های قطعه‌بندی: کدام روش قطعه‌بندی شواهد کامل‌تر و بدون نویزتری به مدل زبانی تحویل می‌دهد؟ چرا؟

۴.۶ فاز ۴: بازسازی سامانه با LangChain

📖 شناسنامه و مشخصات کلیدی این فاز

- **هدف فاز:** بازپاده‌سازی ماژولار خط لوله پایه با فریم‌ورک استاندارد LangChain و مقایسه آن با نسخه مستقیم.
- **ورودی‌ها:** کالکشن‌های نمایه‌شده در Qdrant و مدل‌های تعبیه و زبانی فاز ۳.
- **خروجی‌های مورد انتظار:** پایپ‌لاین مبتنی بر LCEL، جدول مقایسه کارایی و زمان پاسخ دو نسخه.
- **فناوری‌های کلیدی:** LangChain، زبان بیان زنجیره‌ها (LCEL)، ادغام‌ساز langchain-qdrant.
- **مهلت تحویل ایستگاه دوم (فاز ۳ و ۴):** چهارشنبه ۲۱ آبان ۱۴۰۴ (ساعت 23:59) 📅 **بازه دفاع شفاهی:** شنبه ۲۴ تا چهارشنبه ۲۸ آبان ۱۴۰۴

در این فاز، دانشجو سامانه پایه فاز قبل را با استفاده از انتراعات LangChain بازسازی می‌کند تا تجربه عملی از مدیریت جریان داده، زنجیره‌سازی اعلان‌ها و اتصال مؤلفه‌ها در فریم‌ورک‌های استاندارد صنعتی کسب شود.

۱.۴.۶ تطبیق مؤلفه‌ها و زنجیره‌سازی (LCEL)

جریان داده در نسخه LangChain باید دقیقاً منطبق بر معماری مستقیم فاز قبل باشد. تطبیق مؤلفه‌ها به شرح زیر انجام می‌گیرد:

- مدل تعبیه با استفاده از کلاس سفارشی یا استاندارد Embeddings.
- اتصال به پایگاه داده با QdrantVectorStore بدون تغییر نام کالکشن یا بعد بردار.
- ایجاد رتریور با تابع `as_retriever(search_kwargs={"k": 5})`.
- ساخت پرامپت با ChatPromptTemplate و زنجیره‌سازی خروجی با StrOutputParser.

🔧 شرط صحت مقایسه تجربی

جهت حفظ اعتبار علمی مقایسه، تمامی پارامترها شامل نسخه مدل‌ها، بذر تصادفی، مقدار k ، دما (temperature) و متون پرسش‌ها باید میان دو نسخه مستقیم و لانگ‌چین کاملاً یکسان باشند.

۲.۴.۶ تحلیل و هم‌سنجی دو پیاده‌سازی

دانشجو باید پاسخ‌های حاصل از دو نسخه را روی مجموعه‌ای از پرسش‌های منتخب از ابعاد زیر مقایسه کند:

۱. یکتایی و ترتیب قطعات بازیابی شده: آیا قطعات و امتیازات کسینوسی در هر دو نسخه عیناً یکسان هستند؟
۲. زمان اجرای خط لوله (Latency): مقایسه میانگین زمان بازیابی و زمان کل پاسخ‌دهی در هر دو شیوه.
۳. تجرید در برابر شفافیت: بررسی مزایا و معایب فریم‌ورک از منظر سادگی توسعه، قابلیت دیباگ و شخصی‌سازی.

❓ پرسش‌های تحویلی و مستندسازی این فاز

۱. لینک مخزن گیت‌هاب: کد زنجیره **LangChain** و نوت‌بوک اجرای هم‌سنجی.
۲. جدول هم‌سنجی زمان و رتبه: نتایج مقایسه زمان اجرا و رتبه قطعات بازیابی شده را برای ۵ پرسش در جدولی ثبت کنید.
۳. تحلیل سربار (Overhead): آیا استفاده از **LangChain** سربار زمانی یا حافظه‌ای محسوسی ایجاد کرد؟ علت آن چیست؟

۵.۶ فاز ۵: بهینه‌سازی و مقایسه روش‌های بازیابی (Dense, BM25, Hybrid, Reranking)

📖 شناسنامه و مشخصات کلیدی این فاز

- **هدف فاز:** تقویت کیفیت شواهد بازیابی شده از طریق ترکیب روش‌های لغوی و معنایی و پالایش نتایج با مدل بازرتبه‌بند.
- **ورودی‌ها:** پیکره اسناد متنی و کالکشن‌های برداری ایجادشده در فازهای قبل.
- **خروجی‌های مورد انتظار:** پیاده‌سازی **BM25**، بازیابی ترکیبی (**Hybrid**)، بازرتبه‌بند **Cross-Encoder** و جدول مقایسه‌ای.
- **فناوری‌های کلیدی:** **rank_bm25**، الگوریتم **RRF**، مدل‌های بازرتبه‌بند زبان فارسی یا چندزبانه.
- **مهلت تحویل ایستگاه سوم (فاز ۵ و ۶):** چهارشنبه ۱۲ آذر ۱۴۰۴ (ساعت 23:59) 🕒 **بازه دفاع شفاهی:** ۱۵ تا ۱۹ آذر ۱۴۰۴

در این فاز، محدودیت‌های بازیابی صرفاً معنایی (**Dense**) با بهره‌گیری از تطابق واژگانی (**Lexical Search**) و رتبه‌بندی مجدد برطرف شده و عملکرد سامانه ارتقا می‌یابد.

۱.۵.۶ روش‌های بازیابی و تلفیق رتبه‌ها

دانشجو ملزم به پیاده‌سازی و ارزیابی ۴ رویکرد بازیابی مستقل است:

۱. **بازیابی متراکم (Dense Retrieval):** استفاده از بردارهای معنایی و شباهت کسینوسی در **Qdrant**.
۲. **بازیابی تنک (Sparse Retrieval - BM25):** شاخص‌گذاری واژگانی قطعات با الگوریتم **BM25** روی متن نرمال‌شده.
۳. **بازیابی ترکیبی (Hybrid Retrieval):** ادغام رتبه‌های متراکم و تنک با الگوریتم ادغام رتبه متقابل (**Reciprocal Rank Fusion - RRF**):

$$\text{RRF_Score}(d) = \sum_{m \in \{\text{dense}, \text{bm}\}} \frac{1}{k_0 + r_m(d)} \quad (3)$$

که در آن $r_m(d)$ رتبه سند d در روش m بوده و ثابت آرام‌بخش پیش‌فرض برابر $k_0 = 60$ در نظر گرفته می‌شود.

۴. **بازرتبه‌بندی با مدل تقاطعی (Cross-Encoder Reranking):** بازیابی اولیه تعداد بیشتری از نامزدها (مثلاً ۲۰ قطعه با روش ترکیبی) و بازسنجی شباهت جفت پرسش-قطعه با یک مدل بازرتبه‌بند جهت انتخاب ۵ قطعه نهایی.

همچنین دانشجو باید حداقل یکی از تکنیک‌های **Query Expansion** (بسط پرسش با کلمات هم‌معنی حقوقی) یا **Metadata Filtering** (فیلتر اولیه بر مبنای حوزه خانواده یا ارث) را اعمال نماید.

❓ پرسش‌های تحویلی و مستندسازی این فاز

۱. لینک مخزن گیت‌هاب: کد پیاده‌سازی BM25، RRF و ماژول بازرتبه‌بند.
۲. تحلیل عملکرد واژگانی در برابر معنایی: در چه سناریوهایی از اصطلاحات خاص حقوقی (مانند نام دقیق مواد قانونی)، روش BM25 نسبت به بازیابی متراکم برتری نشان داد؟
۳. اثر بازرتبه‌بندی بر دقت شواهد: آیا مدل بازرتبه‌بند موفق شد قطعات دارای تشابه واژگانی سطحی ولی فاقد پاسخ واقعی را از صدر نتایج حذف کند؟ با ذکر مثال نشان دهید.

۶.۶ فاز ۶: مهندسی اعلان و تولید پاسخ (Prompt Engineering)

📖 شناسنامه و مشخصات کلیدی این فاز

- **هدف فاز:** هدایت هوشمند مدل زبانی جهت تولید پاسخ‌های حقوقی مستند، پرهیز از توهم و درج ارجاعات قانونی.
- **ورودی‌ها:** شواهد نهایی و قطعات بازیابی شده از خط لوله بهینه‌شده فاز ۵.
- **خروجی‌های مورد انتظار:** دو استراتژی متفاوت طراحی اعلان، مکانیزم اعتبارسنجی استناد به شواهد و تحلیل کیفی خروجی‌ها.
- **فناوری‌های کلیدی:** مدل‌های زبانی معتبر، قالب‌های اعلان پارامتریک، تکنیک‌های سنجش پایبندی (Groundedness).
- **مهلت تحویل ایستگاه سوم (فاز ۵ و ۶):** چهارشنبه ۱۲ آذر ۱۴۰۴ (ساعت 23:59) **بازه دفاع شفاهی:** شنبه ۱۵ تا چهارشنبه ۱۹ آذر ۱۴۰۴

در این فاز، قطعات بازیابی شده در قالب یک بافتار منسجم (Context) ترکیب شده و همراه با دستورالعمل‌های کنترل‌شده در اختیار مدل زبانی قرار می‌گیرند تا پاسخی دقیق، جامع و مستند به قوانین کشور تولید شود.

۱.۶.۶ طراحی راهبردهای اعلان‌نویسی

دانشجو باید حداقل دو قالب اعلان متفاوت را طراحی و بر روی مجموعه پرسش‌های یکسان ارزیابی کند:

۱. **راهبرد پایبندی سخت‌گیرانه به شواهد (Strict Citation Prompting):** مدل ملزم می‌شود تنها و تنها بر اساس متن مواد قانونی ارائه شده پاسخ دهد و در صورتی که پاسخ در شواهد موجود نباشد، صریحاً اعلام کند «بر اساس قوانین ارائه‌شده پاسخی یافت نشد». همچنین به ازای هر ادعا، شماره ماده یا نام قانون را استناد دهد.
۲. **راهبرد استدلال تحلیلی گام‌به‌گام (CoT / Chain-of-Thought Legal Prompting):** مدل ابتدا مسئله حقوقی را به پیش‌شرط‌ها و شرایط قانونی تفکیک کرده، مواد مرتبط را از شواهد استخراج نموده و سپس نتیجه‌گیری حقوقی را ارائه نماید.

❓ پرسش‌های تحویلی و مستندسازی این فاز

۱. لینک مخزن گیت‌هاب: پیاده‌سازی قالب‌ها و کدهای تولید پاسخ به همراه خروجی مدل.
۲. تحلیل پدیده توهم (Hallucination): ۳ نمونه پرسش چالش‌برانگیز که شواهد بازیابی شده برای پاسخ کامل به آن‌ها ناکافی بود را بررسی کنید. آیا راهبرد اول توانست از تولید پاسخ ساختگی و اطلاعات نادرست توسط مدل جلوگیری کند؟

۳. **دقت استانداردها:** درصد ادعاهای پاسخ‌های تولیدشده که مستند به شماره ماده صحیح و معتبر بودند را در گزارشی تحلیلی ثبت نمایید.

۲.۶ فاز ۷: هماهنگ‌سازی جریان سامانه با LangGraph

📖 شناسنامه و مشخصات کلیدی این فاز

- **هدف فاز:** مدل‌سازی معماری سامانه به‌صورت گراف محاسباتی چندمرحله‌ای، قابل مشاهده و مجهز به منطق تصمیم‌گیری پویا.
- **ورودی‌ها:** مؤلفه‌های مستقل بازیابی، بازرتبه‌بندی و تولید پاسخ پیاده‌سازی شده در فازهای پیشین.
- **خروجی‌های مورد انتظار:** گراف حالت کامل با LangGraph شامل گره‌های پردازشی، یال‌های شرطی و امکان بازنویسی پرسش.
- **فناوری‌های کلیدی:** LangGraph، کلاس StateGraph، ساختار داده وضعیت (TypedDict).
- **مهلت تحویل ایستگاه چهارم (فاز ۷ و ۸):** چهارشنبه ۳ دی ۱۴۰۴ (ساعت 23:59) 📅 **بازه دفاع شفاهی:** ۶ تا ۱۰ دی ۱۴۰۴

در این فاز، دانشجو جریان خطی پردازش را به یک گراف حالت پویا و قابل‌کنترل تبدیل می‌کند تا انعطاف‌پذیری لازم برای مسیریابی شرطی و اصلاح خطاها فراهم آید.

۱.۷.۶ ساختار وضعیت و گره‌های گراف (State & Nodes)

دانشجو باید ساختار وضعیت مشترک (State) را با فیلدهای زیر تعریف نماید:

- **question:** متن اصلی پرسش حقوقی کاربر.
- **domain:** حوزه تشخیص داده‌شده (خانواده یا ارث).
- **documents:** لیست قطعات بازیابی شده به همراه امتیازات شباهت.
- **is_relevant:** پرچم تعیین میزان ارتباط شواهد بازیابی شده با موضوع.
- **generation:** متن پاسخ نهایی تولیدشده توسط مدل زبانی.
- **iteration:** شمارنده تعداد دفعات بازنویسی و تلاش مجدد.

سپس گره‌های اصلی سامانه شامل `analyze_query` (تعیین حوزه و پاک‌سازی)، `retrieve` (بازیابی ترکیبی)، `rerank` (پالایش نامزدها)، `grade_documents` (سنجش ربط مستندات) و `generate` (تولید پاسخ نهایی) پیاده‌سازی می‌شوند.

۲.۷.۶ یال‌های شرطی و حلقه بهبود خودکار (Self-Correction)

با استفاده از یال‌های شرطی (Conditional Edges)، در صورتی که در مرحله سنجش شواهد (`grade_documents`) مشخص شود که اسناد بازیابی شده پاسخگوی سوال نیستند، سامانه به گره `rewrite_query` هدایت شده و پس از بازنویسی مجدد پرسش، مسیر بازیابی را با کلیدواژه‌های ارتقایافته تکرار می‌کند (با سقف حداکثر ۲ مرتبه تکرار).

❓ پرسش‌های تحویلی و مستندسازی این فاز

۱. لینک مخزن گیت‌هاب: کد گراف، تعریف وضعیت و تصویر رندر شده ساختار گراف (graph.png).
۲. ردیابی اجرای یک نمونه شرطی: تاریخچه تغییر مقادیر State در طول اجرای یک پرسش چالش‌برانگیز که وارد حلقه بازنویسی پرسش شد را با جزئیات گزارش کنید.
۳. مزایای گراف حالت نسبت به زنجیره‌های خطی: کنترل‌پذیری و قابلیت مانیتورینگ (Observability) در این معماری چه تفاوتی با زنجیره‌های ساده فاز ۴ دارد؟

۸.۶ فاز ۸: طراحی و پیاده‌سازی Graph RAG

📖 شناسنامه و مشخصات کلیدی این فاز

- **🎯 هدف فاز:** ساخت گراف دانش از متون حقوقی و پیاده‌سازی بازیابی بر مبنای ساختار گرافی جهت حل پرسش‌های چندمرحله‌ای.
- **📁 ورودی‌ها:** پیکره کامل اسناد قوانین مدنی و حمایت خانواده.
- **📡 خروجی‌های مورد انتظار:** شمای گراف دانش (Graph Schema)، پایگاه داده گراف، خط لوله بازیابی گرافی و ارزیابی Multi-hop.
- **🔧 فناوری‌های کلیدی:** NetworkX یا Neo4j، مدل‌های استخراج موجودیت و رابطه (OpenIE/NER)، زبان پرس‌وجوی گراف.
- **📅 مهلت تحویل ایستگاه چهارم (فاز ۷ و ۸):** چهارشنبه ۳ دی ۱۴۰۴ (ساعت 23:59) | **🔒 بازه دفاع شفاهی:** شنبه ۶ تا چهارشنبه ۱۰ دی ۱۴۰۴

در این فاز، دانشجو با عبور از رویکرد صرفاً قطعه‌محور، روابط ساختاری و وابستگی‌های پیچیده میان مواد قانونی را در قالب یک گراف دانش (Knowledge Graph) مدل‌سازی کرده و سازوکار Graph RAG را پایه‌ریزی می‌کند.

۱.۸.۶ طراحی شمای گراف دانش حقوقی (Legal Graph Schema)

دانشجو باید شمای گرافی متناسب با ساختار حقوقی طراحی کند که حداقل شامل موارد زیر باشد:

- **انواع موجودیت‌ها (Entity Types):** ماده قانونی (Article)، مفهوم حقوقی (LegalConcept نظیر ارث، مهریه، نفقه)، نقش‌ها و اشخاص (Role مانند زوج، متوفی، ولی قهری) و شرایط (Condition).
- **انواع روابط (Relation Types):** رابطه شرطی (REQUIRES)، رابطه مانع (EXCLUDES نظیر موانع ارث)، رابطه استثنا یا تخصیص (EXCEPTS) و رابطه ارجاع یا اصلاح (REFERENCES).

۲.۸.۶ استخراج سه‌تایی‌ها و بازیابی گرافی (Graph Retrieval)

برای هر پرسش کاربر، پس از استخراج موجودیت‌های کلیدی پرسش، زیرگراف مرتبط با پیمایش مسیرهای تا عمق ۲ (2-hop Subgraph) استخراج شده و به یک بازنمایی متنی یا سه‌تایی‌های معنادار برای درج در Context مدل زبانی تبدیل می‌شود. عملکرد این روش به‌ویژه در پرسش‌های استدلالی نظیر «محاسبه سهم الارث در صورت وجود حاجب یا طبقات مختلف وراثت» بررسی خواهد شد.

❓ پرسش‌های تحویلی و مستندسازی این فاز

۱. لینک مخزن گیت‌هاب: اسکریپت‌های ساخت گراف، ذخیره‌سازی و نوت‌بوک اجرای بازیابی گرافی.
۲. نمودار و آمار گراف دانش: تعداد رأس‌ها (Nodes)، یال‌ها (Edges) و چگالی گراف استخراج‌شده را گزارش فرمایید.
۳. مقایسه تجربی Vector RAG در برابر Graph RAG: دو پرسش چندمرحله‌ای (Multi-hop) که در آن‌ها روش برداری ساده در بازیابی تمامی مواد مرتبط شکست خورد اما روش گرافی موفق عمل نمود را با تحلیل مسیرهای پیمایش‌شده گزارش دهید.

۹.۶ فاز ۹: ارزیابی نهایی، تحلیل خطا و یکپارچه‌سازی سامانه

📖 شناسنامه و مشخصات کلیدی این فاز

- **هدف فاز:** ارزیابی جامع کمی و کیفی تمام نسخه‌ها تحت پروتکل واحد، اجرای مطالعات ابلیشن و یکپارچه‌سازی خط لوله نهایی.
- **ورودی‌ها:** تمامی نسخه‌های پیاده‌سازی‌شده در فازهای ۱ تا ۸ و داده‌های آزمون (Test Set).
- **خروجی‌های مورد انتظار:** جدول مقایسه نهایی روش‌ها، مستندات دو Ablation Study، تحلیل کیفی خطاها و کد یکپارچه main.py.
- **سنجه‌های ارزیابی:** Recall@k، MRR، nDCG، ROUGE-L، F_۱ و سنجه‌های وفاداری به شواهد (Faithfulness).
- **مهلت تحویل فاز نهایی (فاز ۹):** چهارشنبه ۱ بهمن ۱۴۰۴ (ساعت 23:59) **بازه ارزیابی نهایی و دموي جامع:** شنبه ۴ تا سه‌شنبه ۷ بهمن ۱۴۰۴

در فاز پایانی، تمامی سامانه‌های توسعه‌یافته در طول ترم تحت شرایط کاملاً استاندارد و هم‌تراز ارزیابی می‌شوند. ارزیابی در دو لایه مستقل و تفکیک‌شده انجام می‌گیرد:

۱.۹.۶ ارزیابی کیفیت بازیابی شواهد (Retrieval Evaluation)

در این بخش، کارایی روش‌های مختلف بازیابی (Graph RAG و Reranked، Hybrid، BM25، Dense) با سنجه‌های استاندارد بازیابی اطلاعات سنجیده می‌شود. برای مثال، اگر R_q مجموعه مواد یا قطعات مرتبط طلایی برای پرسش q و $Retrieved_k(q)$ مجموعه k قطعه برتر بازیابی‌شده باشد، سنجه $Recall@k$ به صورت زیر تعریف می‌گردد:

$$Recall@k(q) = \frac{|Retrieved_k(q) \cap R_q|}{|R_q|} \quad (۴)$$

همچنین سنجه‌های دقت در رتبه اول (MRR) و سود تجمعی تنزیل‌یافته نرمال (nDCG@k) باید برای هر روش گزارش شوند.

۲.۹.۶ ارزیابی کیفیت پاسخ نهایی (Generation Evaluation)

کیفیت پاسخ‌های تولیدشده با معیارهای واژه‌محور و معنایی شامل ROUGE-L، Exact Match و همچنین سنجش پابندی پاسخ به شواهد حقوقی ارائه‌شده و پرهیز از توهم (Faithfulness / Hallucination Rate) ارزیابی می‌گردد.

۳.۹.۶ مطالعات ابلیشن و تحلیل خطا (Ablation & Error Analysis)

دانشجو باید دست‌کم دو مطالعه ابلیشن (Ablation Study) مستقل انجام دهد (برای مثال: حذف مرحله بازرتبه‌بندی، یا حذف رویکرد آگاه از ساختار و استفاده از اندازه ثابت). همچنین تحلیل کیفی خطاها (Error Analysis) روی نمونه‌های ناموفق انجام شده و ریشه خطا در یکی از دسته‌های زیر طبقه‌بندی شود:

- آ. خطای بازیابی شواهد (Retrieval Failure) – شواهد مرتبط در بین قطعات بازیابی شده وجود نداشته است.
- ب. خطای رتبه‌بندی (Ranking Failure) – شواهد بازیابی شده اما در رتبه‌های بسیار پایین قرار گرفته و وارد بافتار مدل نشده‌اند.
- ج. خطای استدلال و تولید (Generation / Reasoning Failure) – با وجود حضور شواهد کافی، مدل در استدلال یا استناد دچار اشتباه شده است.

❓ پرسش‌های تحویلی و مستندسازی این فاز

۱. لینک مخزن گیت‌هاب: اسکریپت اجرای نهایی (main.py)، فایل README.md حاوی راهنمای کامل نصب و اجرای مجدد.
۲. جدول جامع مقایسه تمامی روش‌ها: جدول تجمیعی شامل امتیازات تمام سنج‌های بازیابی و تولید برای کلیه نسخه‌های پیاده‌سازی شده در فازهای ۳ تا ۸ روی مجموعه آزمون.
۳. گزارش تفصیلی دو مطالعه ابلیشن: تحلیل عددی و مفهومی اثر حذف یا تغییر دو مؤلفه انتخابی.
۴. نمودار و ماتریس تحلیل خطا: گزارش حداقل ۵ مورد از خطاهای واقعی سامانه به همراه ریشه‌یابی و راهکار پیشنهادی برای رفع آن‌ها.

🎓 چک‌لیست نهایی تحویل و بارگذاری پروژه

- دانشجویان گرامی، پیش از ثبت نهایی پروژه در سامانه آموزش (LMS)، لطفاً اطمینان حاصل فرمایید:
- تمامی کدهای ۹ فاز به صورت مازولار در مخزن گیت‌هاب سازمان‌دهی شده و فایل README.md شامل راهنمای محیط مجازی، نصب پیش‌نیازها و دستور اجرای فایل main.py باشد.
 - فایل گزارش نهایی پروژه در قالب PDF منسجم شامل تحلیل‌ها، جداول مقایسه‌ای و نمودارهای خواسته‌شده ضمیمه شود.
 - نام و شماره دانشجویی در ابتدای گزارش و فایل README.md درج گردیده باشد.

با آرزوی موفقیت و کسب تجارب عمیق در پیاده‌سازی سامانه‌های پیشرفته پردازش زبان طبیعی