

به نام آن که جان را فکرت آموخت

آزمون اول درس پردازش زبان طبیعی پیشرفته

مدت آزمون: ۷۰ دقیقه

مجموع بارم: ۱۰۰ نمره

نام و نام خانوادگی: شماره دانشجویی:

۱. [۱۴ نمره] در مدل Skip-gram، احتمال شرطی مشاهده کلمه بافت o به شرط کلمه مرکزی c با تابع Naive Softmax به صورت زیر محاسبه می شود:

$$P(o | c) = \frac{\exp(u_o^T v_c)}{\sum_{w \in V} \exp(u_w^T v_c)}$$

(آ) فرض کنید banking کلمه مرکزی (c) و regulation یکی از کلمات بافت (o) باشد. توضیح دهید چرا برای هر کلمه دو بردار u_w و v_w در نظر گرفته می شود و ضرب داخلی، تابع نمایی و مخرج کسر (نرمال سازی) هر کدام چه نقشی دارند. (۱۴ نمره)

۲. [۱۶ نمره] برای کاهش هزینه محاسباتی Naive Softmax در Word2Vec، از روش نمونه برداری منفی (Negative Sampling) استفاده می شود:

(آ) ایده اصلی این روش چیست و چگونه پیش بینی واژگان را به رگرسیون لجستیک دوتایی (Binary Logistic Regression) تبدیل می کند؟ (۵ نمره)

(ب) زوج واقعی را (banking, regulation) و یک نمونه منفی مانند (banking, banana) در نظر بگیرید. هدف یادگیری مدل را برای زوج واقعی در مقایسه با نمونه های منفی مشخص کرده و تابع هدف را برای این کلمه مرکزی با استفاده از سیگموئید σ و K نمونه منفی فرمول بندی کنید. (۶ نمره)

(ج) در نمونه برداری منفی، کلمات منفی با توزیع $P(w) \propto U(w)^{3/4}$ انتخاب می شوند که در آن $U(w)$ توزیع یک گرامی است. اثر این توان را بر احتمال نمونه برداری کلمات کم بسامد و پر بسامد نسبت به $U(w)$ توضیح دهید. (۵ نمره)

۳. [۱۶ نمره] مدل Bigram را با شمارش بیشینه ی درست نمایی (MLE) و بدون هموارسازی روی پیکره ی زیر آموزش دهید:

<s> I like NLP </s>
<s> I like deep learning </s>
<s> you like NLP </s>

(آ) احتمال های $P(I | <s>)$ ، $P(like | I)$ ، $P(NLP | like)$ و $P(</s> | NLP)$ را بیابید. (۵ نمره)

(ب) احتمال جمله ی اول و سرگشتگی (Perplexity) آن روی ۴ توکن پیش بینی شده را حساب کنید (نیازی به محاسبه ی عددی اعشاری یا ریشه ی چهارم نیست؛ نوشتن پاسخ به صورت کسر یا توان کسری کافی است) و معنای شهودی مقدار کمتر سرگشتگی را توضیح دهید. (۵ نمره)

(ج) احتمال جمله ی $<s> I love NLP </s>$ بر اساس این مدل چیست؟ این مقدار بیانگر چه مشکلی در برآورد MLE است؟ یک راه حل برای رفع آن نام برده و توضیح دهید با افزایش n ، فضای حافظه و تعداد پارامترهای جدول مدل (Memory footprint) با چه نرخ رشد می کند. (۶ نمره)

۴. [۱۶ نمره] روابط حالت در دو معماری LSTM و GRU به ترتیب به صورت زیر هستند:

$$\begin{aligned}c_t^{\text{LSTM}} &= f_t \circ c_{t-1} + i_t \circ \tilde{c}_t, \\h_t^{\text{LSTM}} &= o_t \circ \tanh(c_t), \\h_t^{\text{GRU}} &= (1 - z_t) \circ \tilde{h}_t + z_t \circ h_{t-1}.\end{aligned}$$

(آ) چه دروازه‌هایی در LSTM حفظ حالت قبلی را ممکن می‌کنند و چرا مسیر جمعی در به‌روزرسانی حالت سلول به جریان گرادین در طول زمان کمک می‌کند؟ (۸ نمره)

(ب) اثر مقادیر $z_t \approx 0$ و $z_t \approx 1$ و نقش دروازه‌ی بازنشانی (Reset Gate) در GRU چیست؟ (۸ نمره)

۵. [۱۸ نمره] با توجه به مشخصات معماری مدل ترنسفورمر فقط-رمزگشا (Decoder-Only، مشابه ساختار GPT-2 Small) در جدول زیر، به پرسش‌ها پاسخ دهید (نیازی به محاسبه‌ی عددی ضرب‌های بزرگ نیست؛ نوشتن روابط ابعاد و حاصل ضرب‌ها کفایت می‌کند):

- Layers (L) = 12
- Token embedding (d) = 768 (12×64)
- FFN hidden dimension (d_{ff}) = 3072
- Attention heads (h) = 12
- Head dimension (d_k) = 64
- Vocabulary size ($|V|$) = 50,257
- Context length ($T_{\max}$) = 1024

(آ) ابعاد ماتریس‌های وزن پرس‌وجو، کلید، مقدار و خروجی (W_Q, W_K, W_V, W_O) را در لایه خودتوجه چندسر (Multi-Head Attention) مشخص کرده و تعداد کل پارامترهای وزن این بخش را در یک لایه به‌دست آورید. (۶ نمره)

(ب) ابعاد ماتریس‌های وزن دو لایه خطی (W_1, W_2) در شبکه‌ی پیش‌خور (FFN) را تعیین کرده و تعداد کل پارامترهای وزن آن را در یک لایه بنویسید. (۶ نمره)

(ج) ابعاد ماتریس تعبیه کلمات (W_e) و تعبیه موقعیت (W_{pos}) را مشخص کرده و رابطه‌ی تعداد کل پارامترهای وزنی مدل را شامل تعبیه‌ها و ۱۲ لایه بنویسید (صرفاً ماتریس‌های وزن، بدون بایاس و LayerNorm). (۶ نمره)

۶. [۲۰ نمره] در یک مدل Transformer، ماتریس توجه علی (Causal Attention) به صورت زیر محاسبه می‌شود:

$$A = \text{softmax} \left(\frac{QK^T}{\sqrt{d_k}} + M \right)$$

شکل زیر اعمال ماسک علی را برای جمله ۴ توکنی «I hate this movie» نشان می‌دهد (✓: مجاز، ×: نامجاز/آینده):

		Keys (K)			
		I	hate	this	movie
Queries (Q)	I	✓	×	×	×
	hate	✓	✓	×	×
	this	✓	✓	✓	×
	movie	✓	✓	✓	✓

(آ) درایه‌های ماتریس ماسک M در موقعیت‌های مجاز (✓) و نامجاز (×) چه مقادیری باید اختیار کنند تا توجه به توکن‌های آینده در خروجی مسدود گردد؟ (۵ نمره)

(ب) با استناد به رابطه تحلیلی تابع Softmax اثبات نمایید که چرا مقادیر انتخابی شما منجر به صفر شدن دقیق درایه‌های خروجی ماتریس A می‌شود و چرا در تئوری، یک عدد منفی بزرگ متناهی (مانند -10^9) نمی‌تواند خروجی دقیقاً صفر تولید کند. (۷ نمره)

(ج) نقش ضریب مقیاس‌بندی $\frac{1}{\sqrt{d_k}}$ در رابطه توجه چیست؟ در صورت حذف این ضریب با افزایش بعد d_k ، چه مشکلی برای مقادیر ضرب داخلی، خروجی تابع Softmax و گرادین‌ها در زمان آموزش رخ می‌دهد؟ (۸ نمره)

فرمول‌های کمکی (در صورت نیاز):

$$\sigma(z) = \frac{1}{1 + e^{-z}}, \quad \text{softmax}(z_i) = \frac{e^{z_i}}{\sum_j e^{z_j}},$$

$$P_{\text{bi}}(w_t | w_{t-1}) = \frac{\text{count}(w_{t-1}, w_t)}{\text{count}(w_{t-1})}, \quad \text{PPL} = \exp \left(-\frac{1}{T} \sum_{t=1}^T \log P(w_t | w_{<t}) \right)$$