به نام آن که جان را فکرت آموخت

آزمون دوم درس پردازش زبان طبیعی پیشرفته

مدت آزمون: ۸۰ دقیقه **مجموع بارم: ۱۰۰ نمره**

نام و نام خانوادگی: ..... **شماره دانشجویی:** .....

---

۱. مزایا و محدودیت‌های توکن‌سازهای زیرواژه‌ای: (۲۱ نمره)

(آ) **[۷ نمره]** سه رویکرد توکن‌سازی Subword، Word و Character/Byte را از نظر طول دنبالهٔ ورودی، اندازهٔ واژگان و مسئلهٔ کلمات خارج از واژگان (OOV) مقایسه کنید.

(ب) **[۷ نمره]** در برخی پیاده‌سازی‌ها، متن پیش از آموزش BPE بر پایهٔ فاصله پیش‌توکن‌بندی می‌شود. این انتخاب برای زبان‌هایی مانند چینی، ژاپنی و تایلندی چه محدودیتی ایجاد می‌کند؟ در فارسی، اگر نیم‌فاصله به‌عنوان مرز پیش‌توکن‌ها در نظر گرفته شود، چه اثری دارد؟ اثر این محدودیت‌ها را بر طول دنباله و واژگان آموخته‌شده توضیح دهید.

(ج) **[۷ نمره]** جایگاه SentencePiece را در فرایند توکن‌سازی توضیح دهید. آن را از نظر الگوریتم‌ها و شیوهٔ آماده‌سازی متن با BPE مقایسه کنید و نقش مرزبندی فاصله‌ای را بررسی کنید.

---

۲. مدل‌سازی زبان پوشانده‌شده در BERT: (۲۰ نمره)

می‌دانیم مدل BERT از روش مدل‌سازی زبان پوشانده‌شده (Masked Language Modeling - MLM) استفاده می‌کند. در این روش 15% از موقعیت‌های توکن برای سازوکار MLM انتخاب می‌شوند و برای هر موقعیت انتخاب‌شده یکی از حالت‌های زیر رخ می‌دهد:

(a) 80% را با توکن ویژه [MASK] عوض می‌کنیم.
(b) 10% را با یک توکن تصادفی عوض می‌کنیم.
(c) 10% از توکن‌ها را تغییر نمی‌دهیم.

فرض کنید از یک مجموعه‌داده با ۲ میلیون توکن استفاده می‌کنیم:

(آ) **[۴ نمره]** تعداد کل توکن‌های انتخاب‌شده برای پیش‌بینی و تعداد مورد انتظار توکن‌های هر یک از حالت‌های ،(a) (b) و (c) را محاسبه کنید.

(ب) **[۳ نمره]** چه تعدادی از موقعیت‌های انتخاب‌شده در محاسبهٔ زیان آموزش (Training Loss) تأثیر دارند؟ دلیل خود را کوتاه توضیح دهید.

(ج) **[۸ نمره]** چرا همهٔ توکن‌های انتخاب‌شده را با [MASK] عوض نمی‌کنیم؟ توضیح دهید این کار چه تفاوتی بین پیش‌آموزش و استفادهٔ بعدی از مدل ایجاد می‌کند. همچنین بگویید جایگزینی با توکن تصادفی و تغییرندادن بعضی توکن‌ها چه کمکی می‌کند.

(د) **[۵ نمره]** فرض کنید به‌جای ٪۱۵ توکن‌ها، از همهٔ آن‌ها برای پیش‌بینی استفاده کنیم. به چه مشکلی برمی‌خوریم؟

---

۳. تخصیص بهینهٔ منابع محاسباتی بر پایهٔ قوانین مقیاس‌پذیری: (۲۲ نمره)

رابطهٔ تجربی Kaplan et al. (2020) را در نظر بگیرید:

$$L(N, D) = \left[\left(\frac{N_c}{N} \right)^{\frac{\alpha_N}{\alpha_D}} + \frac{D_c}{D} \right]^{\alpha_D}$$

برای بخش‌های (ب) و (ج)، بودجهٔ محاسباتی را با تقریب $C \approx 6ND$ در نظر بگیرید و فرض کنید هر توکن آموزشی یک‌بار در محاسبهٔ بودجهٔ FLOPs شمرده می‌شود؛ همچنین $\alpha_N, \alpha_D > 0$ هستند.

(آ) **[۶ نمره]** نمادهای $L, N, D, N_c, D_c, \alpha_N, \alpha_D$ را معرفی کنید. توضیح دهید این رابطه چه وابستگی‌ای را میان اندازهٔ مدل و مقدار دادهٔ آموزشی از یک سو و زیان از سوی دیگر مدل می‌کند و L به چه زیانی اشاره دارد.

(ب) **[۱۰ نمره]** با استفاده از رابطهٔ بالا و قید $C \approx 6ND$، شرط مرتبهٔ اول بهینگی و رابطهٔ میان N^* و D^* را برای کمینه‌کردن زیان در بودجهٔ محاسباتی ثابت به دست آورید. راهنمایی: چون $\alpha_D > 0$ است، می‌توانید عبارت داخل کروشه را کمینه کنید؛ نیازی به بررسی مشتق دوم نیست.

(ج) **[۶ نمره]** اگر بودجهٔ محاسباتی از C به $2C$ افزایش یابد، نسبت‌های $N^*(2C)/N^*(C)$ و $D^*(2C)/D^*(C)$ را بر حسب α_N و α_D به دست آورید. از رابطهٔ بهینهٔ بخش (ب) استفاده کنید؛ نیازی به استخراج جداگانهٔ ضرایب ثابت نیست.

---

۴. تنظیم دقیق کم‌هزینه و تقطیر دانش: **(۱۷ نمره)**

(آ) **[۱۲ نمره]** در روش‌های LoRA، Prefix-Tuning و Adapter، برای سازگارکردن یک مدل ازپیش‌آموزش‌دیده با وظیفهٔ جدید چه پارامترهایی آموزش داده می‌شوند و این پارامترها در کدام بخش از محاسبهٔ ترنسفورمر وارد می‌شوند؟

(ب) **[۵ نمره]** در تقطیر دانش، استفاده از واگرایی Reverse KL را با Forward KL مقایسه کنید. توضیح دهید تفاوت این دو جهتِ واگرایی چه اثری بر رفتار مدل دانش‌آموز در تولید متن می‌گذارد.

---

۵. اثر تجمعی احتمال توکن‌های دُم و نمونه‌برداری Top-p: **(۲۰ نمره)**

در تولید متن با یک مدل زبانی خودبازگشتی، فرض کنید در هر گام احتمال انتخاب توکن از دُم توزیع برابر با $\epsilon = 0.01$ باشد. همچنین فرض کنید این احتمال در تمام گام‌ها ثابت است و انتخاب توکن‌ها در گام‌های متوالی مستقل از یکدیگر است. مدل یک دنبالهٔ ۱۷ توکنی تولید می‌کند.

(آ) **[۶ نمره]** احتمال اینکه در طول تولید این دنباله، دست‌کم یک توکن از دُم توزیع انتخاب شود را محاسبه کنید.

(ب) **[۵ نمره]** با استفاده از رابطهٔ احتمال اجتناب از خطا در یک دنباله به طول T، توضیح دهید با افزایش طول دنباله، احتمال انتخاب دست‌کم یک توکن از دُم چگونه تغییر می‌کند. نتیجهٔ خود را از منظر تولید دنباله‌های بلند تحلیل کنید.

(ج) **[۹ نمره]** نمونه‌برداری Top-p را با Top-k مقایسه کنید. توضیح دهید انتخاب تطبیقی مجموعهٔ کاندیدها بر اساس جرم احتمال تجمعی در Top-p چگونه به کنترل انتخاب توکن‌های کم‌احتمال کمک می‌کند. سپس رفتار این دو روش را برای توزیع‌های احتمال تخت (Flat) و تیز (Peaked) مقایسه کنید.